Systemsoftware

Linux Systemarchitektur

Prof. Dr. Michael Mächtel

Informatik, HTWG Konstanz

Version vom 03.04.17

Übersicht

Übersicht

Lizenzfrage

- Kernel steht unter der GNU Public License (GPL):
  - Modifikationen am Code, die nicht für den Eigenbedarf bestimmt sind, müssen veröffentlicht werden.
  - Lizenzbestimmungen müssen dem Gerät/Produkt beigelegt werden.

Lizenz von Gerätetreiber

- Torvalds: Gerätetreiber sind bereits „Modifikation des Kernel-Codes“.
- Binärtreiber werden (ungern und noch) toleriert.
- Treibercode muss Lizenzbedingung spezifizieren.
- Kernel-Interfaces differenzieren zwischen GPL und Non-GPL-Treibern:
  - Non-GPL-Treiber können nur auf ein Subset der Funktionen zurückgreifen.

Übersicht

Spezifische Werkzeuge/Programme sind nicht notwendig!

- Editor (vi, emacs, kate)
- Make
- (Cross-) Compiler
- (Cross-) Linker
- Versionsverwaltung
- IDE steht nur eingeschränkt zur Verfügung
- Sehr eingeschränktes Debugging

Debugging

- 'I'm afraid that I've seen too many people fix bugs by looking at debugger output, and that almost inevitably leads to fixing the symptoms rather than the underlying problem.'

Linux Kernel Coding Style …

Linus Torvalds:

„*This*[1] *is a short document describing the preferred coding style for the linux kernel. Coding style is very personal, and I won't force my views on anybody, but this is what goes for anything that I have to be able to maintain, and I'd prefer it for most other things too. Please at least consider the points made here.*

First off, I'd suggest printing out a copy of the GNU coding standards, …
"

[1] /usr/src/linux/Documentation/CodingStyle

. . . continued

„First off, I'd suggest printing out a copy of the GNU coding standards, . . .“

„ . . .and NOT read it. Burn them, it's a great symbolic gesture.“

Coding Style in Kernel Code

- Im Kernel wird der Kernighan & Ritchie Stil verwendet.
- Variablen werden klein geschrieben.
- Im Variablennamen verbirgt sich keine Typinformation.
- Öffnende Block-Klammern werden am Ende des vorausgehenden Statements gesetzt.
- Schließende Block-Klammern werden bündig zur aktuellen Einrückungstiefe gesetzt.
- Es wird grundsätzlich ein Tabulator von 8 Zeichen verwendet.
- Gotos sind erlaubt, wenn sie zu kürzerem, effizienten Code führen.

Kernelprogrammierung

- Innerhalb des Kernels stehen nur eingeschränkt Bibliotheksfunktionen zur Verfügung.
- Innerhalb des Kernels darf kein Floating-Point verwendet werden.
- Kernelcode steht nur ein eingeschränkter Stack zur Verfügung (4–8kByte).
- Kernelcode ist performance-optimiert programmiert (Stichwort goto).
- Innerhalb des Kernels gibt es keinen Speicherschutz.

Übersicht

Systemübersicht (1)

- Monolithischer Betriebssystemkern.
- Prioritätengesteuertes Scheduling (mit Round-Robin oder FCFS).
- Untertützung für Tasks und Threads.
- Verschiedenste Dateisysteme:
  - ext2/ext3/ext4
  - vfat
  - jffs2 (journaled flash filesystem)
  - …

Systemübersicht (2)

- Unterstützung für unterschiedliche Systemarchitekturen und Prozessoren
- Speicherverwaltung
- Security Mechanismen
  - Firewall
  - Zugriffslisten
  - Intrusion Detection
  - ...
- Bekannte Programmierschnittstelle

Systemmerkmale aus Anwendersicht

- Zugriff auf Peripherie ist auf den Dateizugriff abgebildet.
- 3 „Dateien“ sind für jeden Rechenprozess direkt zugreifbar:
  - STDIN
  - STDOUT
  - STDERR
- Systeminformationen und Systemzustände sind im Proc-Filesystem abrufbar:
  - cat /proc/cpuinfo
  - cat /proc/interrupts

Übersicht über den Linux Kernel

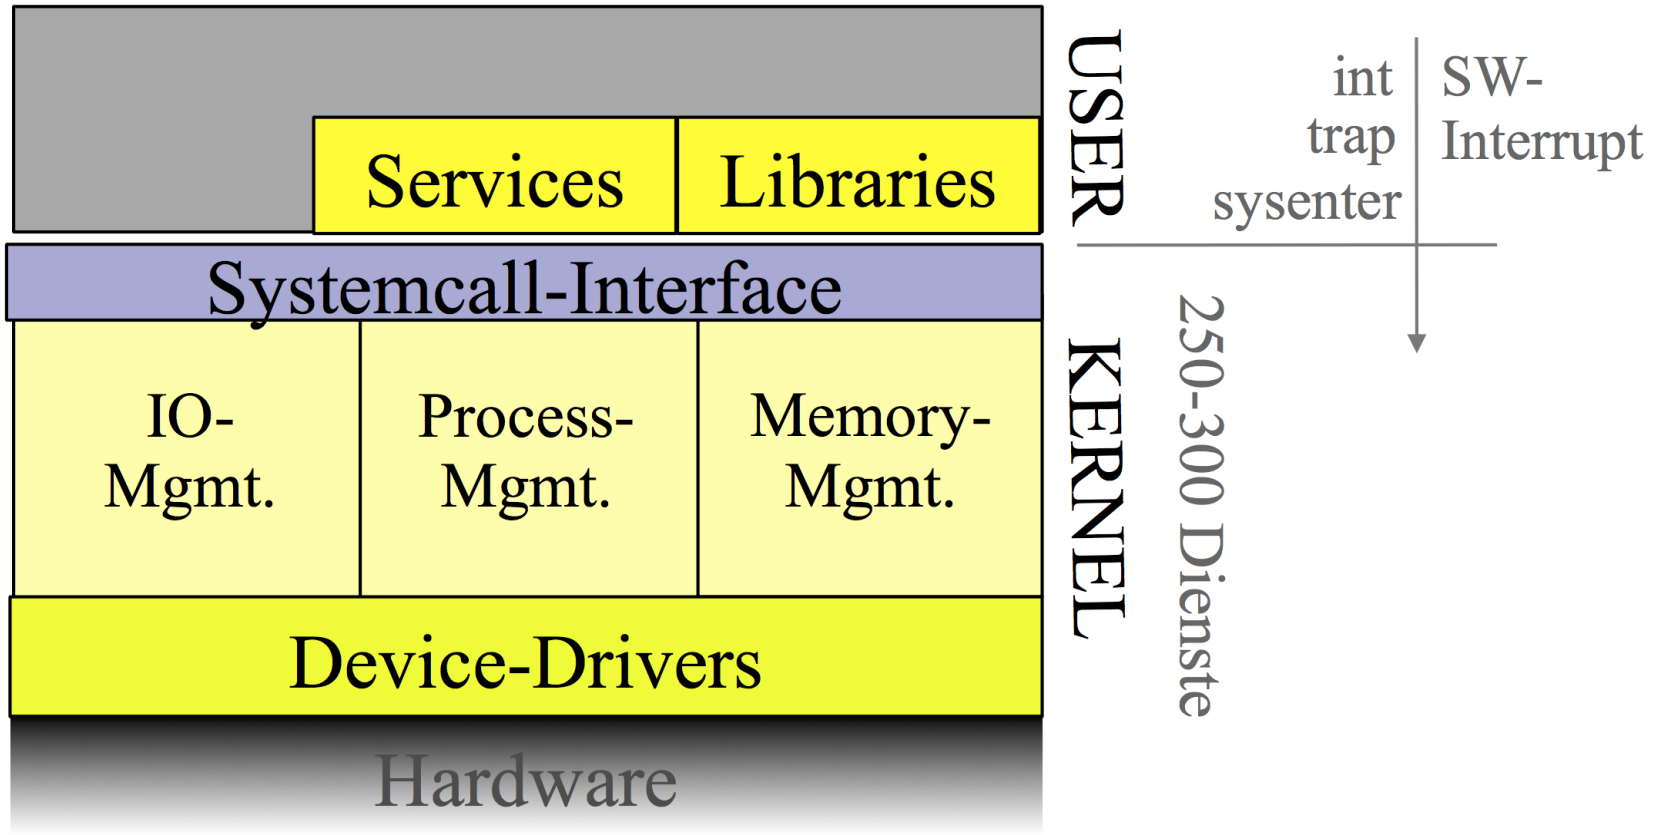

Systemcall Interface

- Dienstzugangsschnittstelle
- Unabhängig von Programmiersprachen
- Realisiert über Softwareinterrupt 0x80 (synchron zum Programmablauf, Assemblerbefehl *INT* oder *sysenter*)
- Argumentenübergabe über Register oder über den Stack
- Alle Systemcalls unter Linux sind im Headerfile <*asm/unistd.h*> aufgeführt

Syscalls

```
#define __NR_exit                1
#define __NR_fork                2
#define __NR_read                3
#define __NR_write               4
#define __NR_open                5
#define __NR_close               6
#define __NR_waitpid             7
#define __NR_creat               8
#define __NR_link                9
#define __NR_unlink              10
#define __NR_execve              11
#define __NR_chdir               12
#define __NR_time                13
#define __NR_mknod               14
#define __NR_chmod               15
#define __NR_lchown              16
#define __NR_break               17
#define __NR_oldstat             18
#define __NR_lseek               19
#define __NR_getpid              20
#define __NR_mount               21
#define __NR_umount              22
#define __NR_setuid              23
#define __NR_getuid              24
#define __NR_stime               25
#define __NR_ptrace              26
#define __NR_alarm               27
#define __NR_oldfstat            28
#define __NR_pause               29
#define __NR_utime               30
#define __NR_stty                31
...
```

Syscallaufruf

```
.text
.globl write_hello_world
write_hello_world:
    movl $4,%eax          ; //code fuer write systemcall
    movl $1,%ebx          ; //file descriptor fd (1=stdout)
    movl $message,%ecx    ; //Adresse des Textes (buffer)
    movl $12,%edx         ; //Laenge des auszugebenden Textes
    int $0x80             ; //SW-Interrupt, Auftrag an das BS
    ret
.data
message:
    .ascii "Hello World\n"
```

Prozessmanagement

- Aufgabe
  - Verteilung der Ressource CPU (Scheduling)
- Schedulingverfahren:
  - Prioritätengesteuertes Scheduling mit überlagertem Round-Robin oder FCFS.

Scheduling

Prioritätengesteuertes Scheduling
Innerhalb einer Prioritätsebene: Zeitscheiben

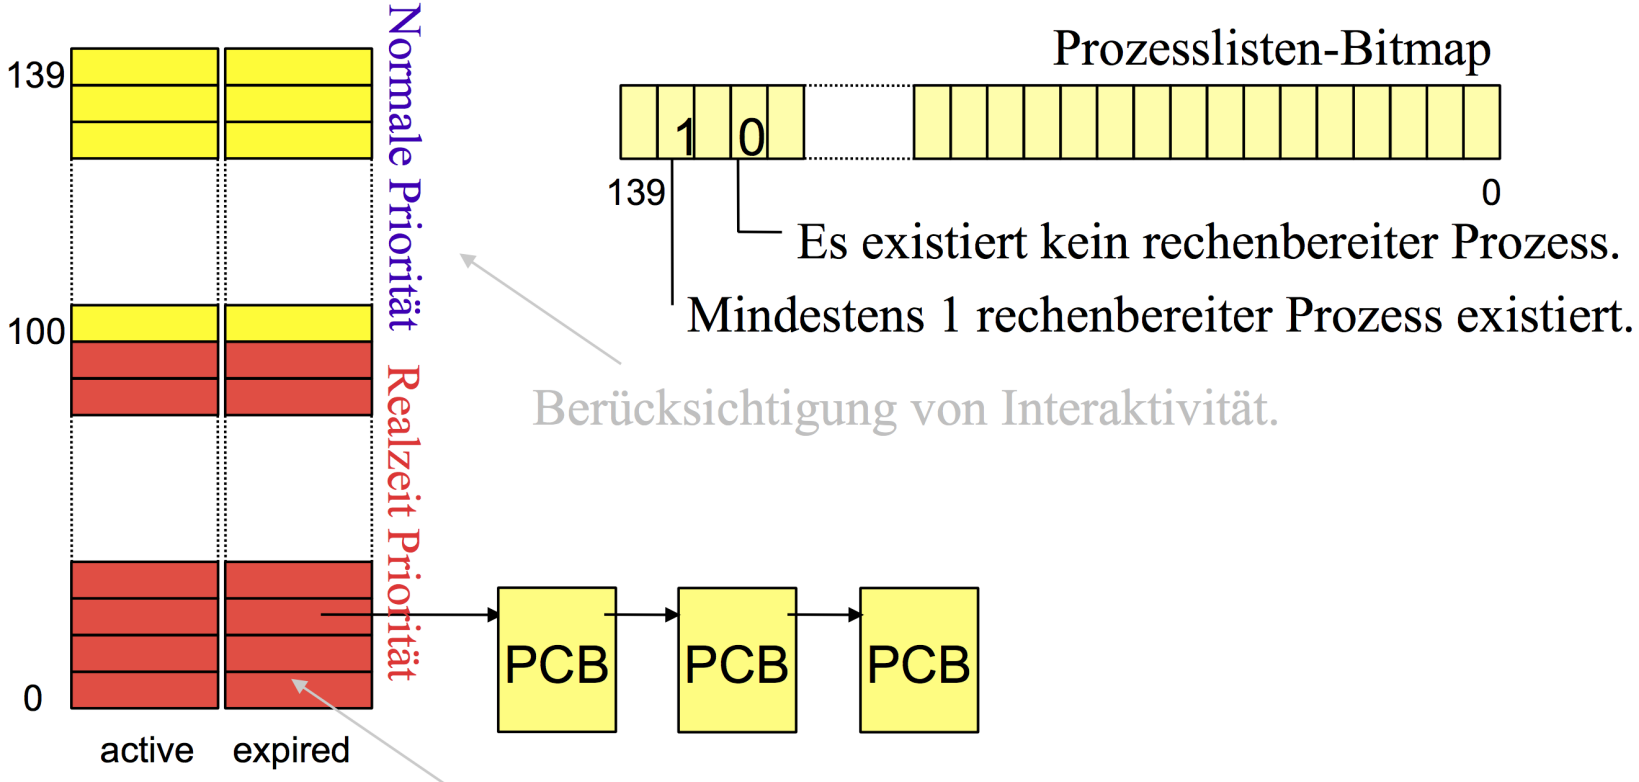

Task Kontrollblock (Prozess /Thread)

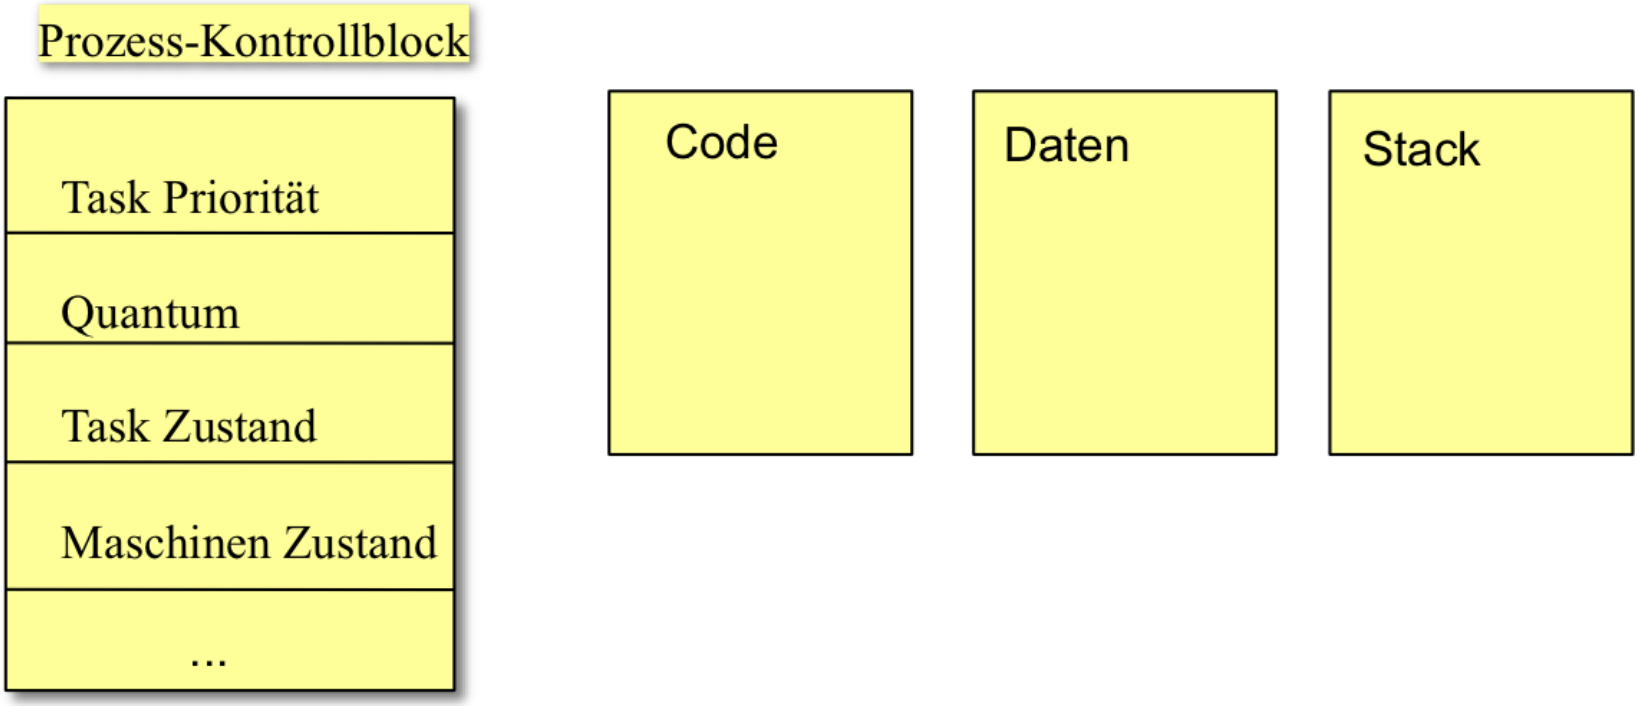

Task = TCB + Code + Daten + Stack
Thread = TCB + Stack (Code + Daten geteilt)

task_struct in Linux

```
struct task_struct {
      volatile long state; /* -1 unrunnable, 0 runnable, >0 stopped */
      ...
      struct exec_domain exec_domain; /* code segment */
      ...
      pid_t pid;
      pid_t pgrp;
      pid_t tty_old_pgrp;
      pid_t session;
      pid_t tgid;
      ...
      int swappable:1;
      uid_t uid, euid, suid, fsuid;
      gid_t gid, egid, sgid, fsgid;
      ...
      struct thread_struct thread; /* machine state */
      ...
};
```

Taskzustände (Theorie)

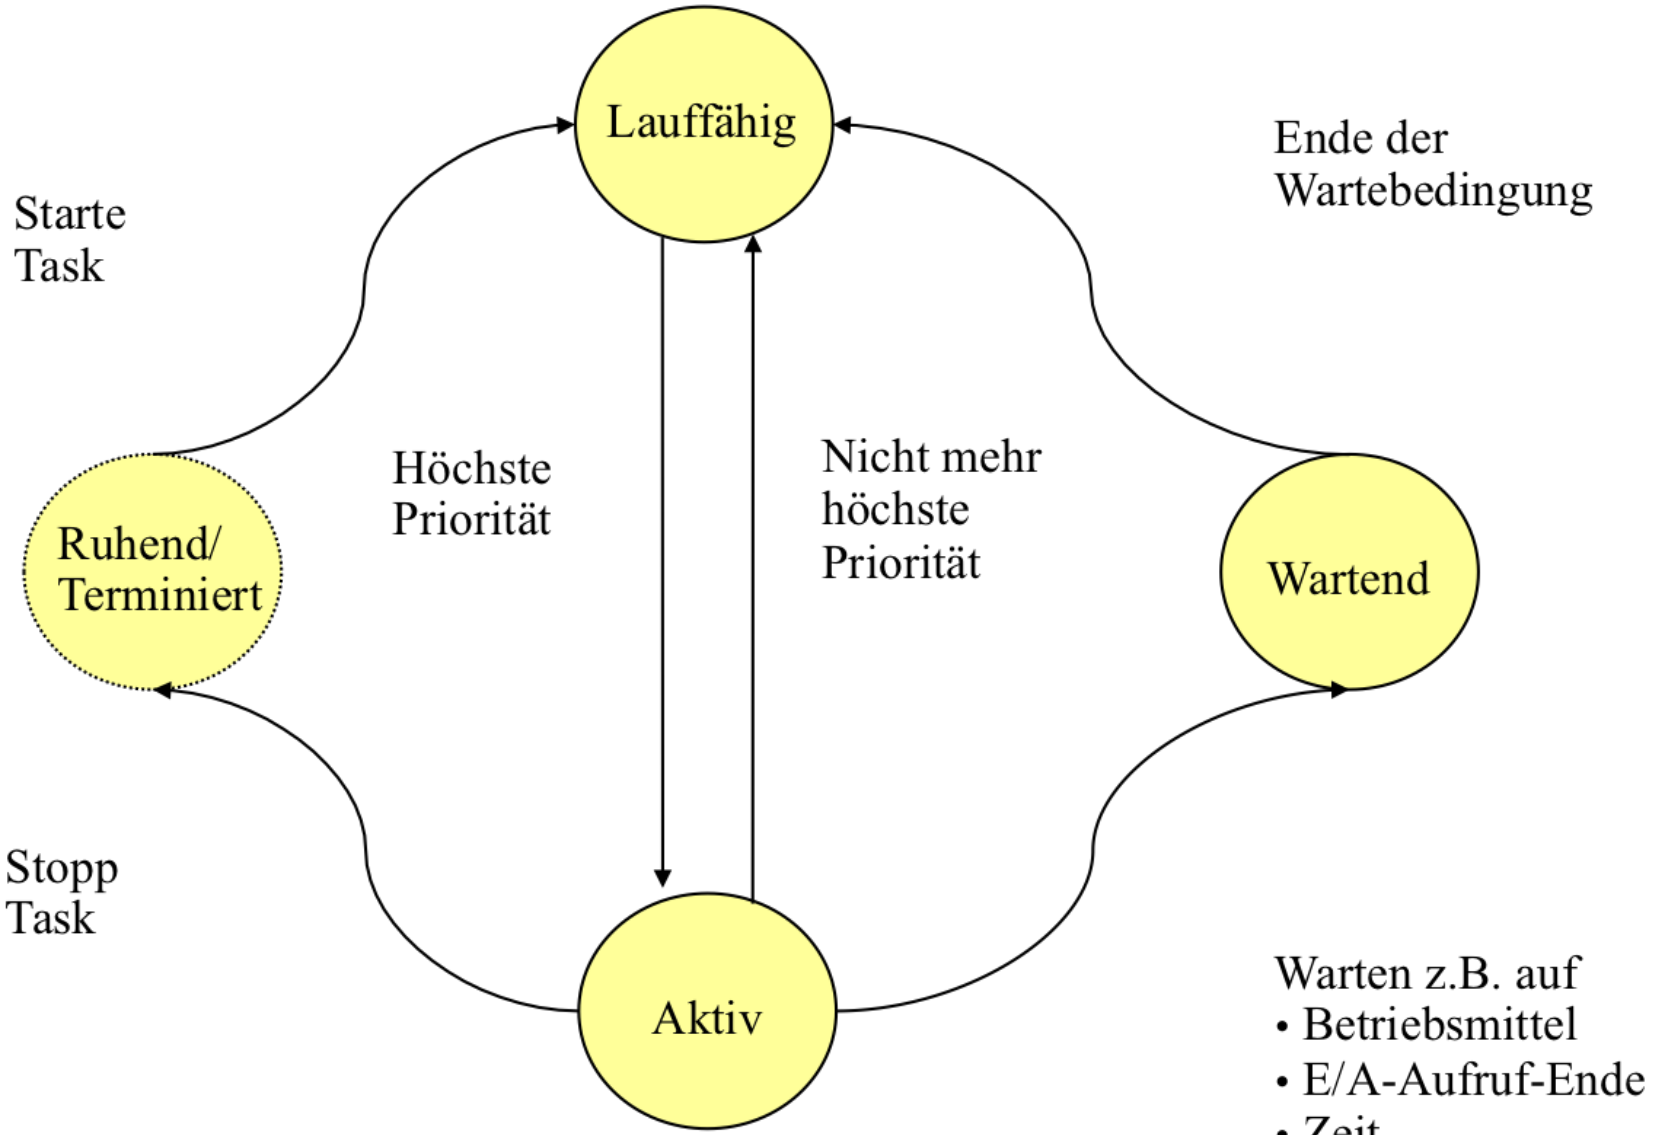

Memory Management

- Aufgabe
  - Speicherschutz
  - Adressumsetzung
  - Virtuellen Speicher zur Verfügung stellen
  - Unterstützung von extended Memory (Highmem)
- User-Space: Speicherbereiche der Applikation
- Kernel-Space: Speicherbereiche des Kernels
- Jede Task hat ihren eigenen Speicherbereich.
- Applikationen können nicht auf den Speicherbereich des Kernels zugreifen.
- Auch der Kernel kann nicht einfach auf den Speicherbereich einer Applikation zugreifen.

Überblick über den Linux Kernel

- Speicher wird in Pages eingeteilt:
  - 32 Bit-Systeme:
    - 2-stufige Speicherverwaltung (two-level paging)
    - Page Directory, Page Table, (Page)
    - 4096 Byte/Page
  - 64 Bit-Systeme:
    - 3-stufige Speicherverwaltung (three-level paging)
    - Page Directory, Page Middle Directory, Page Table, (Page)
    - 8192 Byte/Page
    - Adressraum: 43 Bit, 8 Terabyte

PageTable

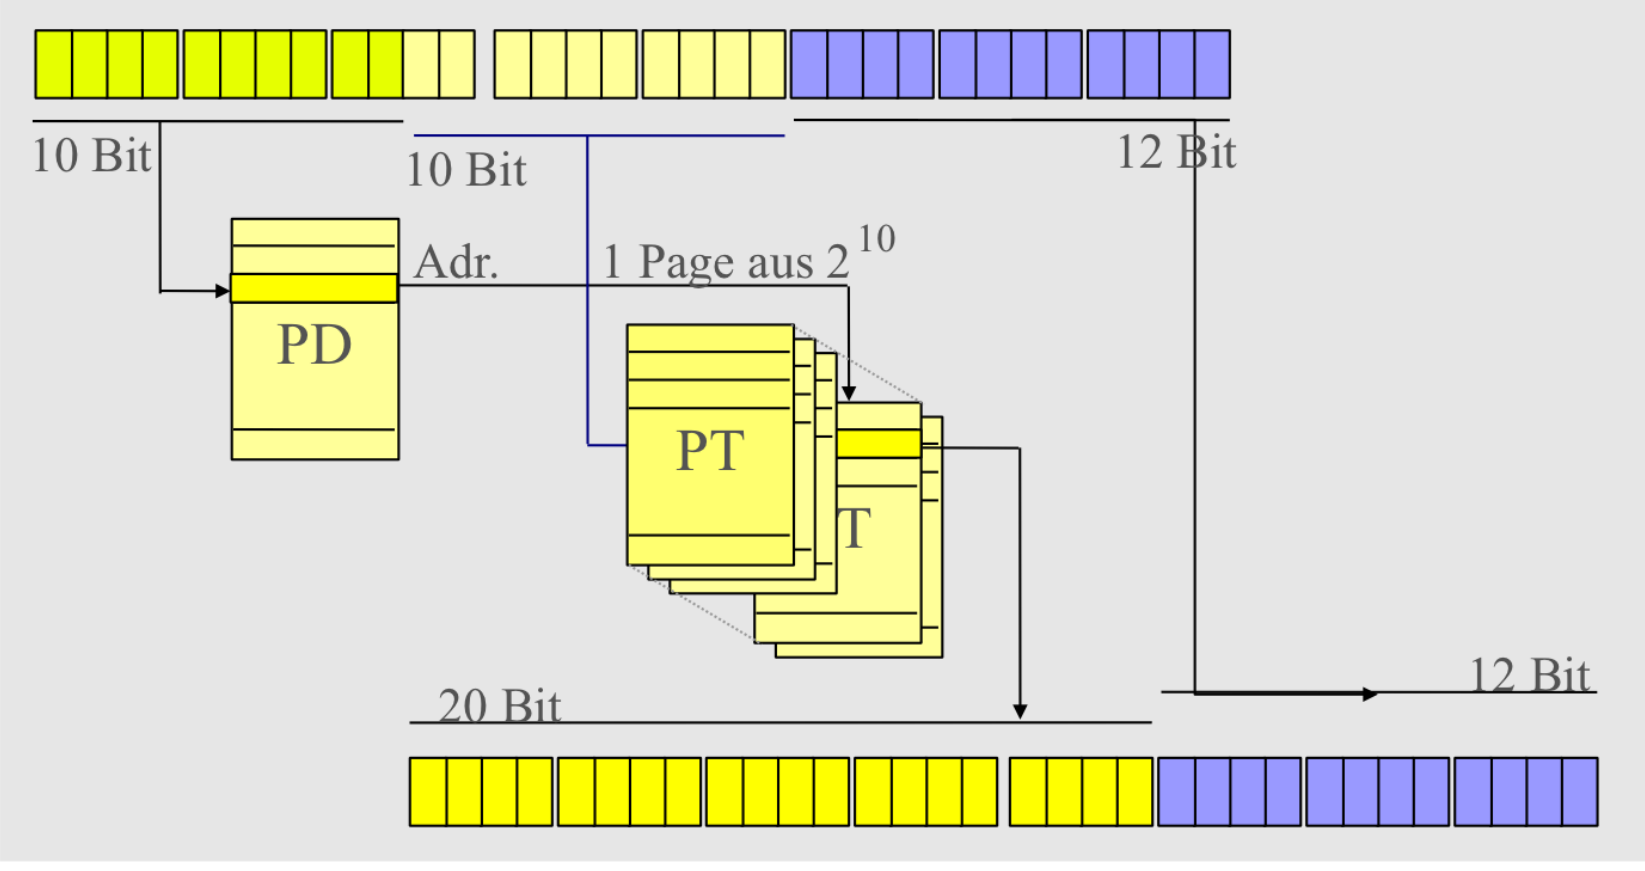

Adressraum Kernel/User

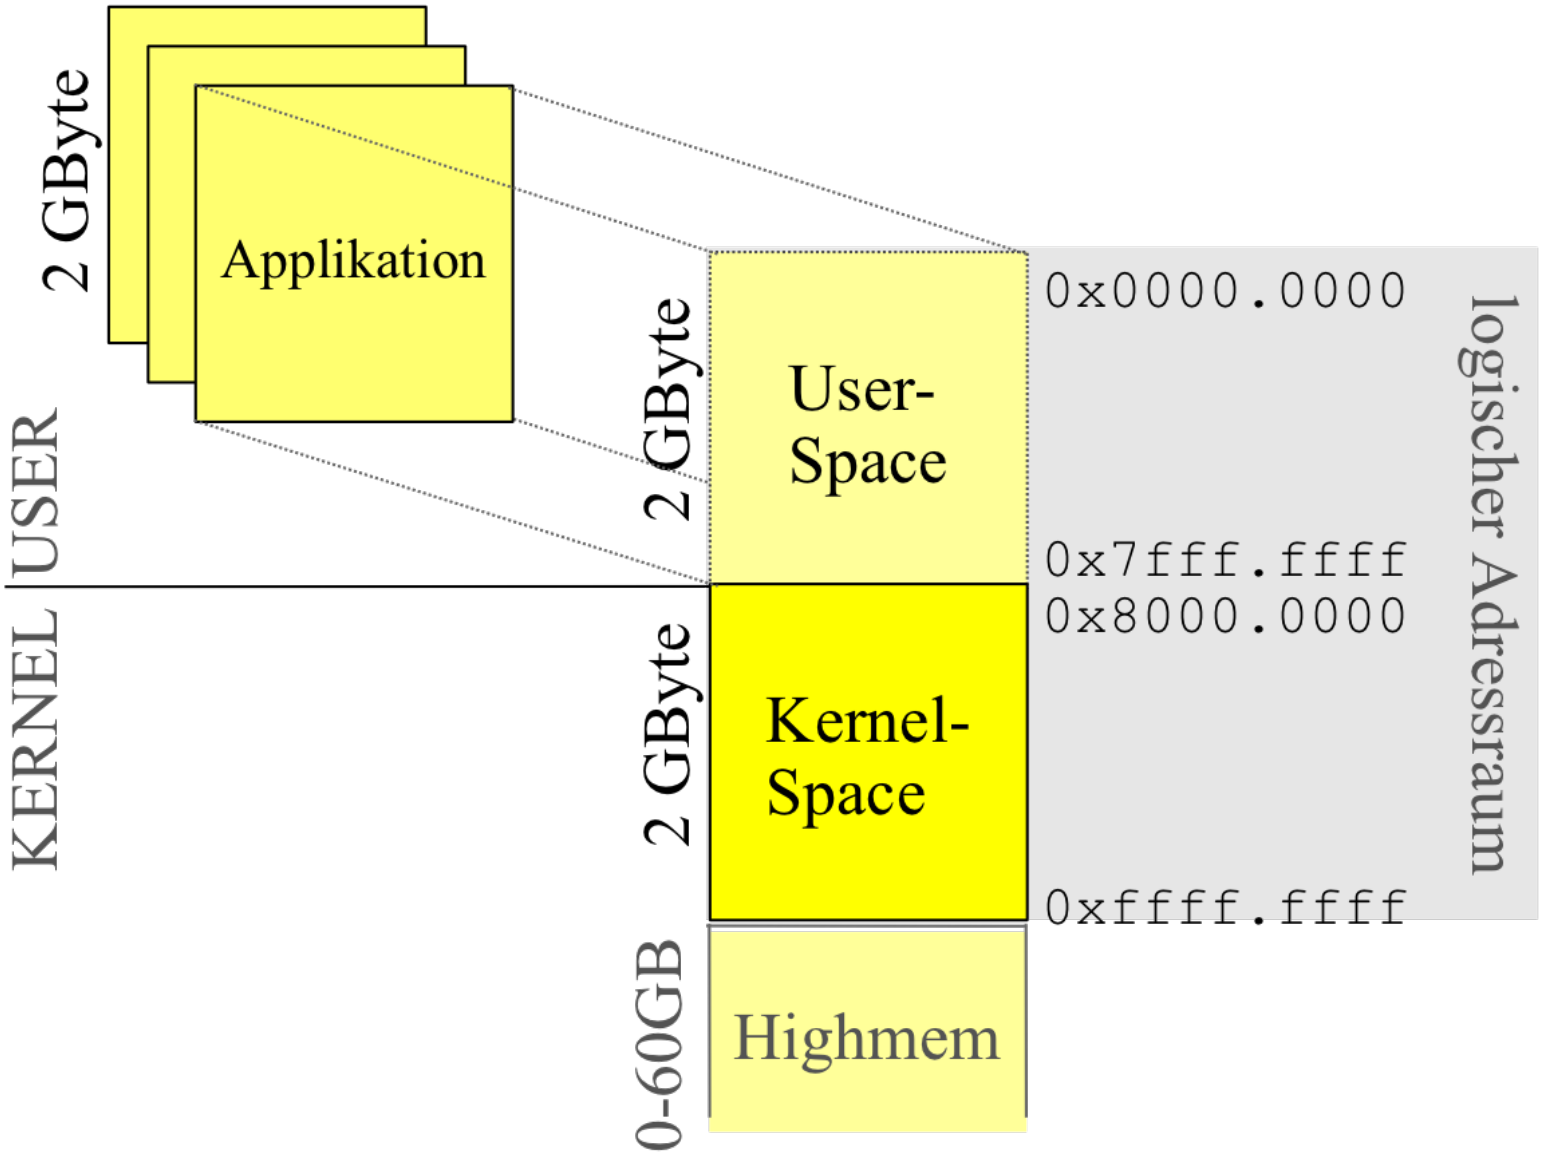

Unterbrechungsmodell

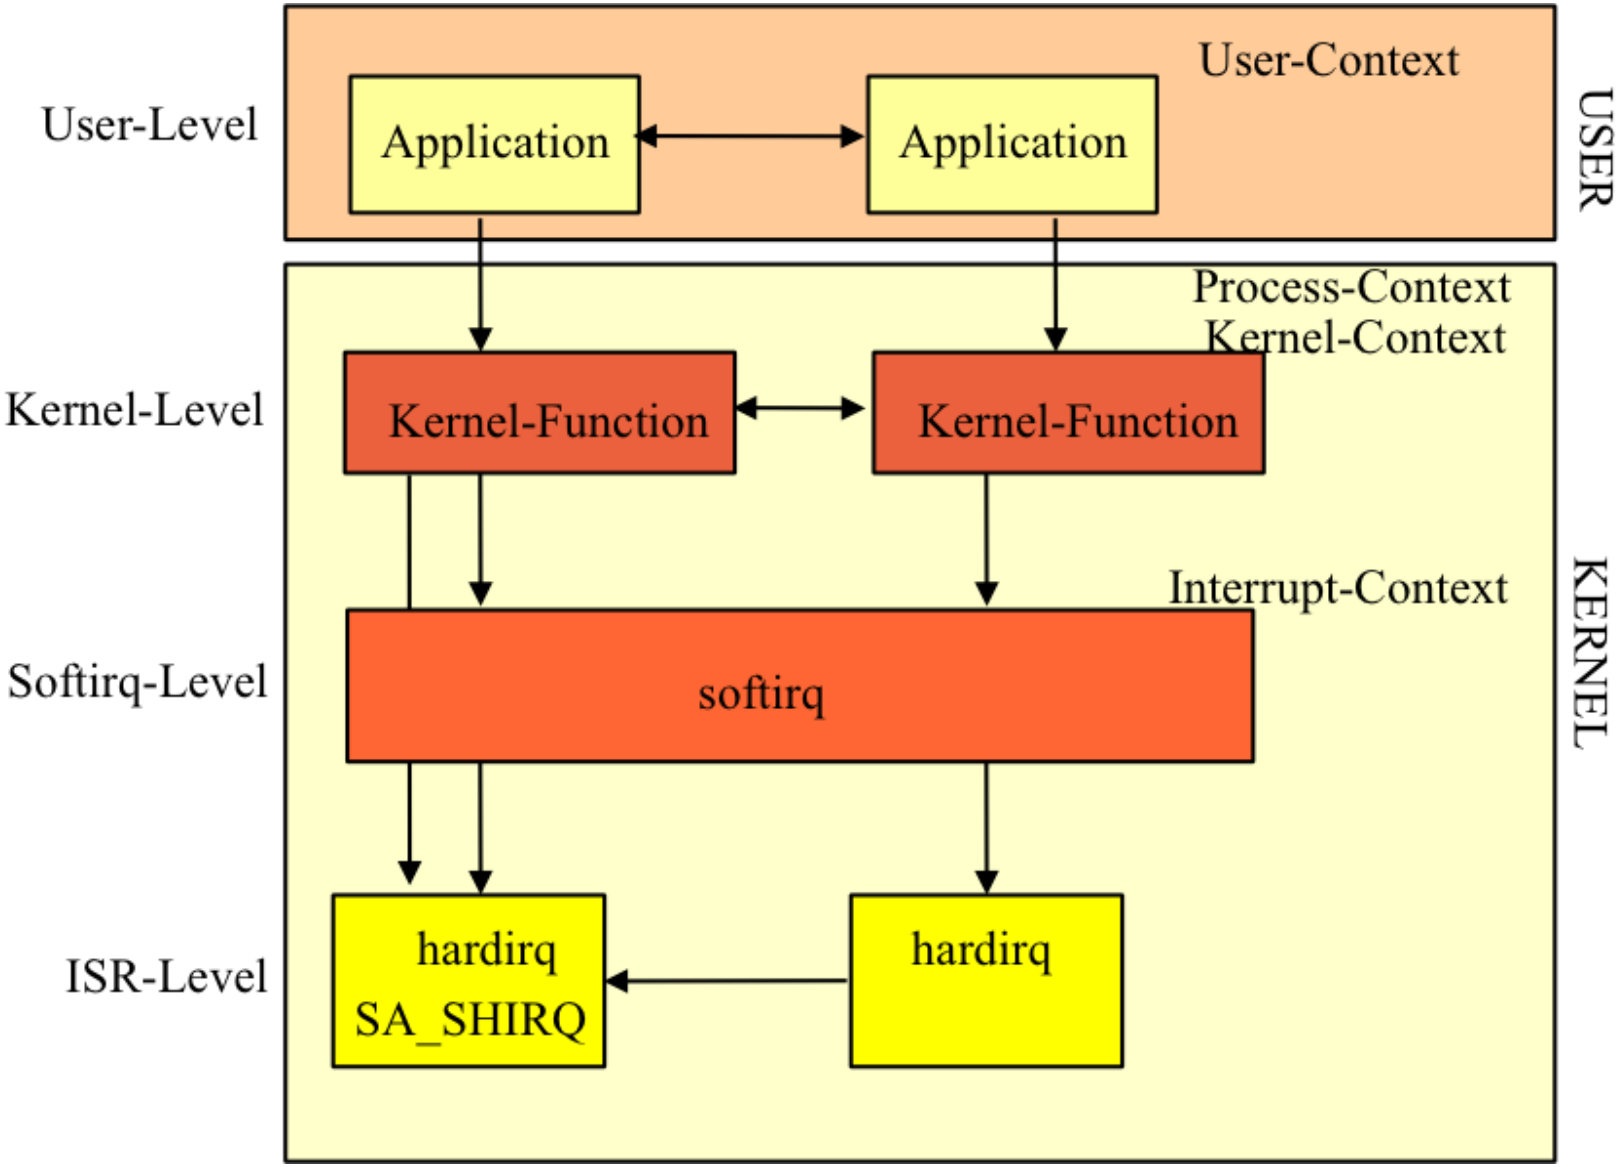

Kernel Preemption (1)

- Code, der im Kernel im Kontext eines Prozesses ausgeführt wird (Prozess-Kontext), wird unterbrochen,
  - wenn ein höherpriorer Rechenprozess lauffähig wird.
- Code, der damit unterbrechbar geworden ist:
  - Applikationsgetriggerte Treiberfunktionen (driver_open, driver_close, driver_read, driver_write)
  - Systemcalls (z.B. insmod, gettimeofday, ...)
  - Kernel-Threads (Kernel-Kontext)
- Funktionen im Kernel- oder Prozesskontext waren schon immer durch Funktionen im Interruptkontext unterbrechbar:
  - Soft-IRQs (bottom-halves, Taskqueues, etc.)
  - Hardware-ISR

Kernel Preemption (2)

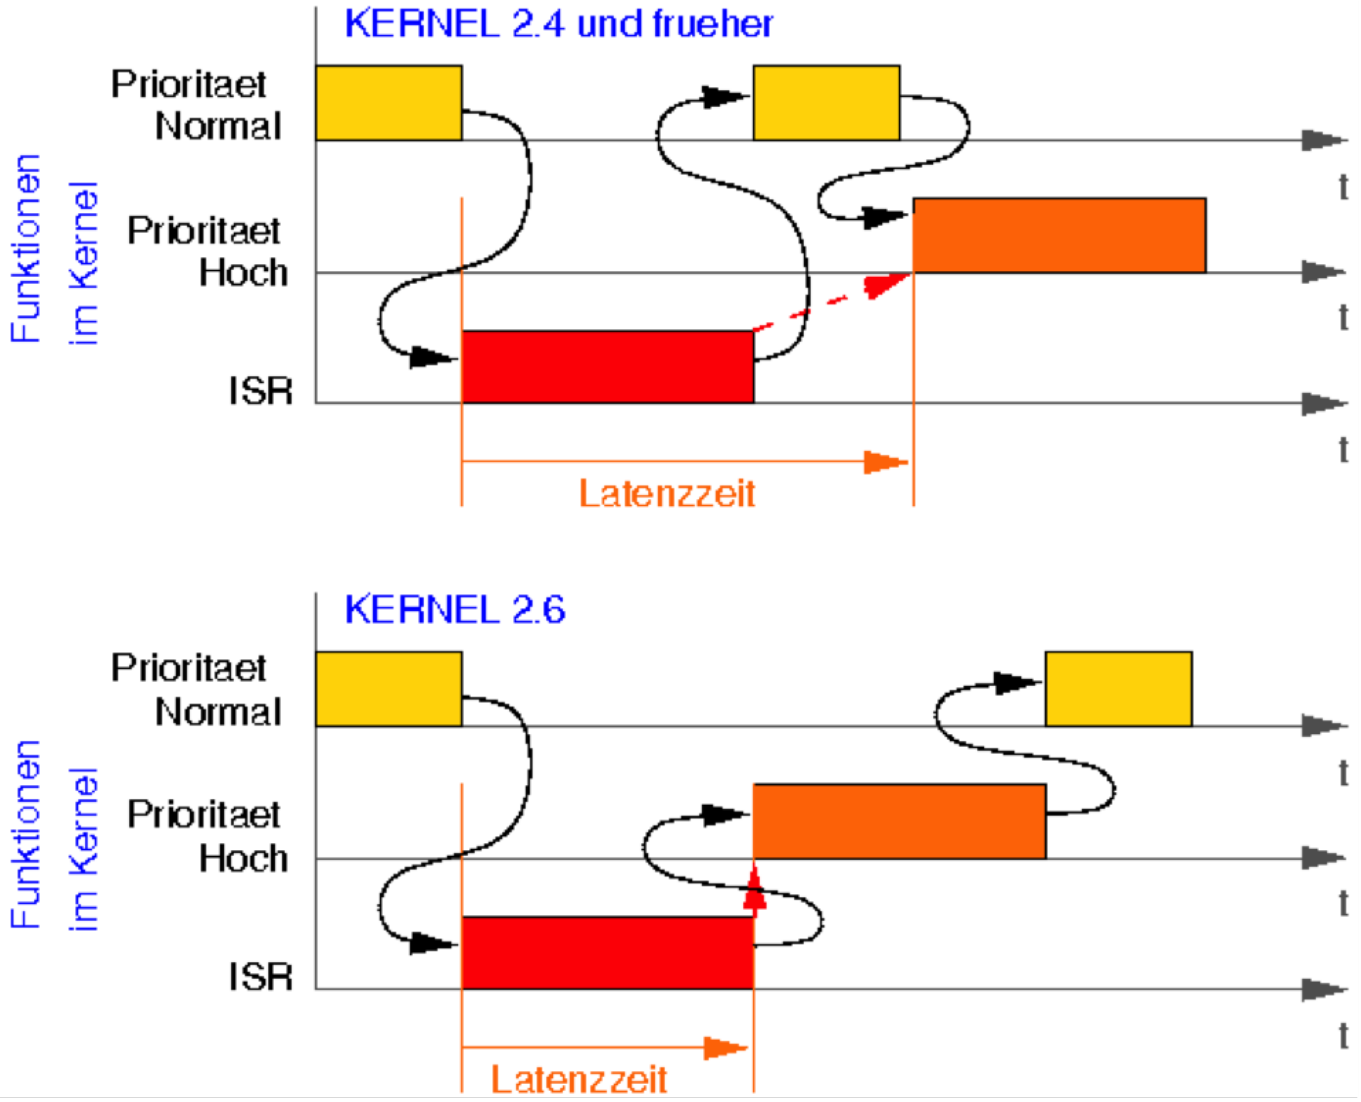

IO Subsystem

- Das IO-Subsystem ermöglicht den einheitlichen Zugriff auf Peripherie.
- Implementiert Filesysteme.
- Ermöglicht die systemkonforme Einbindung von Hardware.

Architektur des Blockgeräte-Subsystem

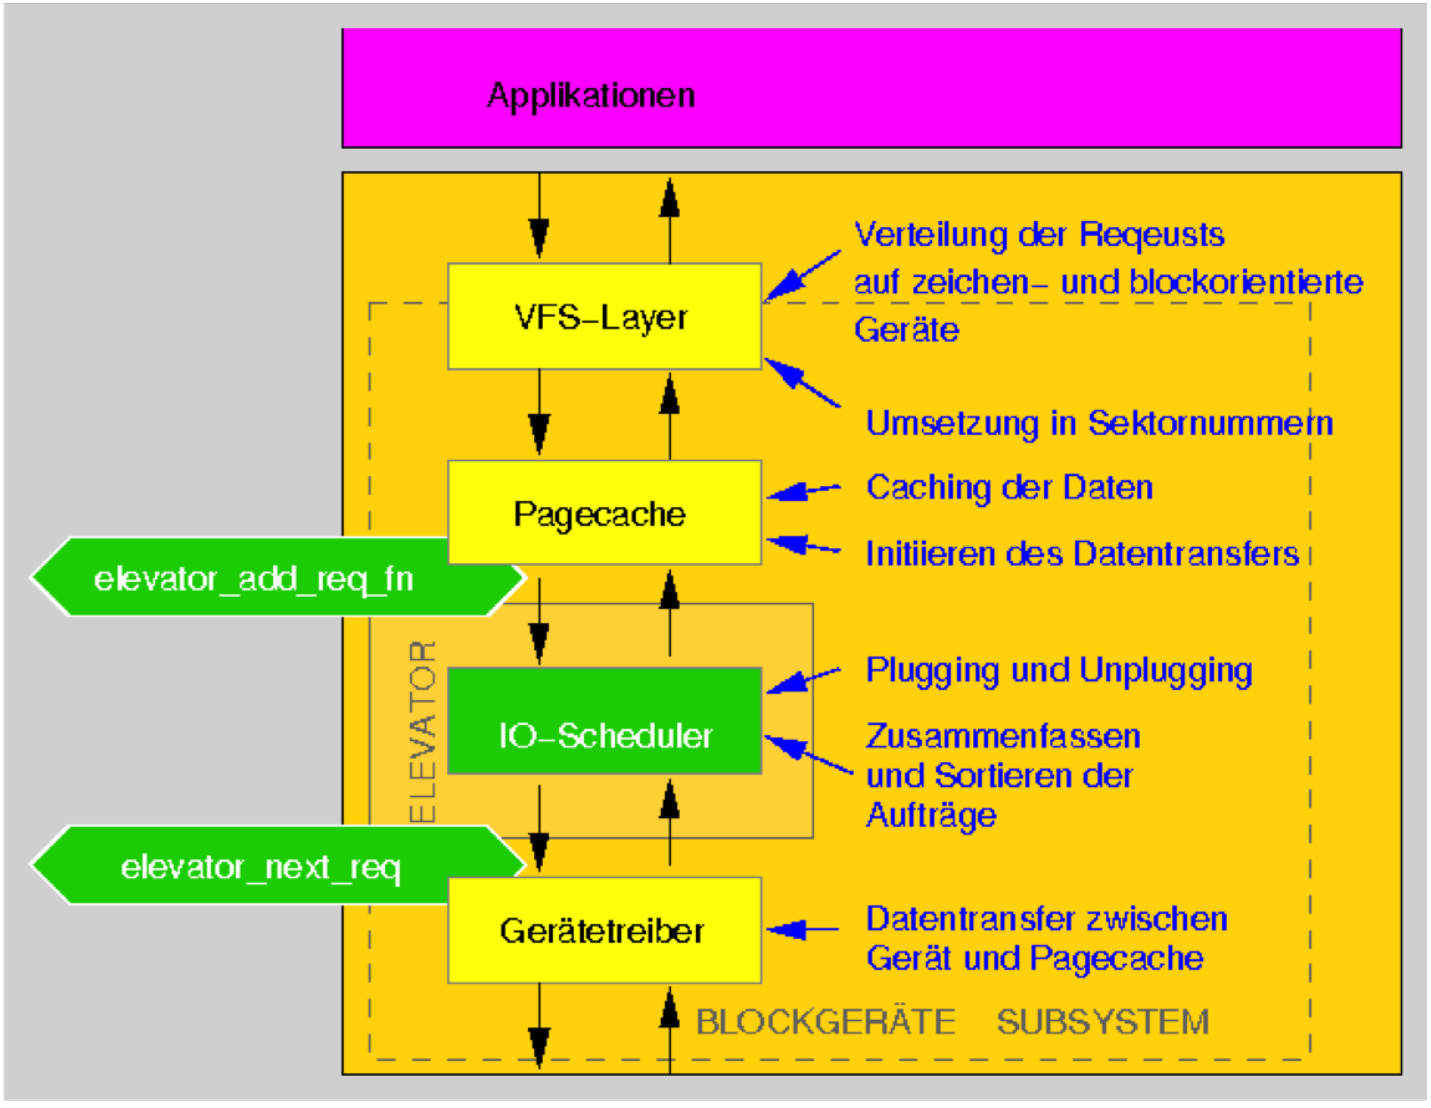

Nutzungsmöglichkeiten des IO-Subsystems

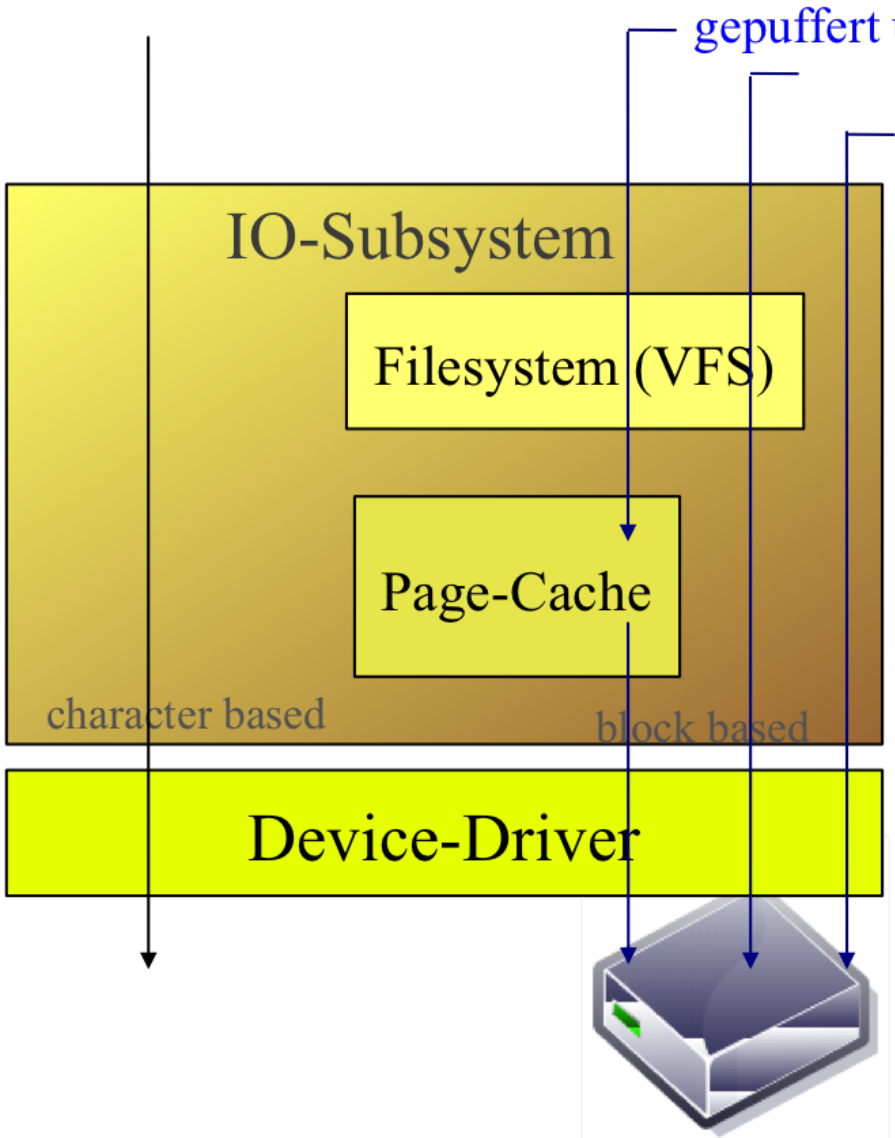

Zusätzlich:
- blockierender Zugriff
- nicht blockierender Zugriff
- asynchroner Zugriff

Gerätetreiber

- Unix: Für den Applikations-Programmierer ist es kein Unterschied, ob er auf Dateien oder auf Geräte zugreift.
- Gerätetreiber führen den eigentlichen (Hardware-)Zugriff auf die Geräte durch.
- Es gibt Treiber für reale Geräte und für virtuelle Geräte (z.B. /dev/null).
- Treiber können als
  - Module oder als
  - Build-In-Treiber implementiert werden.

Gerätearten

- Betriebssystemintern werden mehrere Arten von Geräten unterschieden:
  - Character-Devices
  - Block-Devices
  - Network-Devices
  - USB-Devices
  - …

Character Devices

- Geräte, die die Ein- und/oder Ausgaben zeichenweise durchführen (z.B. Keyboard).
- Gelesene Zeichen können nicht ein zweites Mal gelesen werden.
- Zuordnung zwischen Gerätedatei und Treiber über Major- und Minornumber.

Block-Devices

- Geräte, die die Daten in Blöcken organisieren und übertragen (z.B. Festplatte).
- Der „wahlfreie“ Zugriff auf die Daten ist möglich (seeken).
- Daten werden blockweise gelesen und geschrieben.
- Zuordnung zwischen Gerätedatei und Treiber über Major- und Minornumber.

Treiber Identifikation

- Treiber müssen an der Applikationsschnittsstelle „sichtbar“ gemacht werden:
  - Character-Devices: Eintrag im Filesystem (Gerätedatei)
  - Block-Devices: Eintrag im Filesystem (Gerätedatei)
  - Network-Devices: Name (Parameter beim **ifconfig**)

Funktionen eines Gerätetreibers

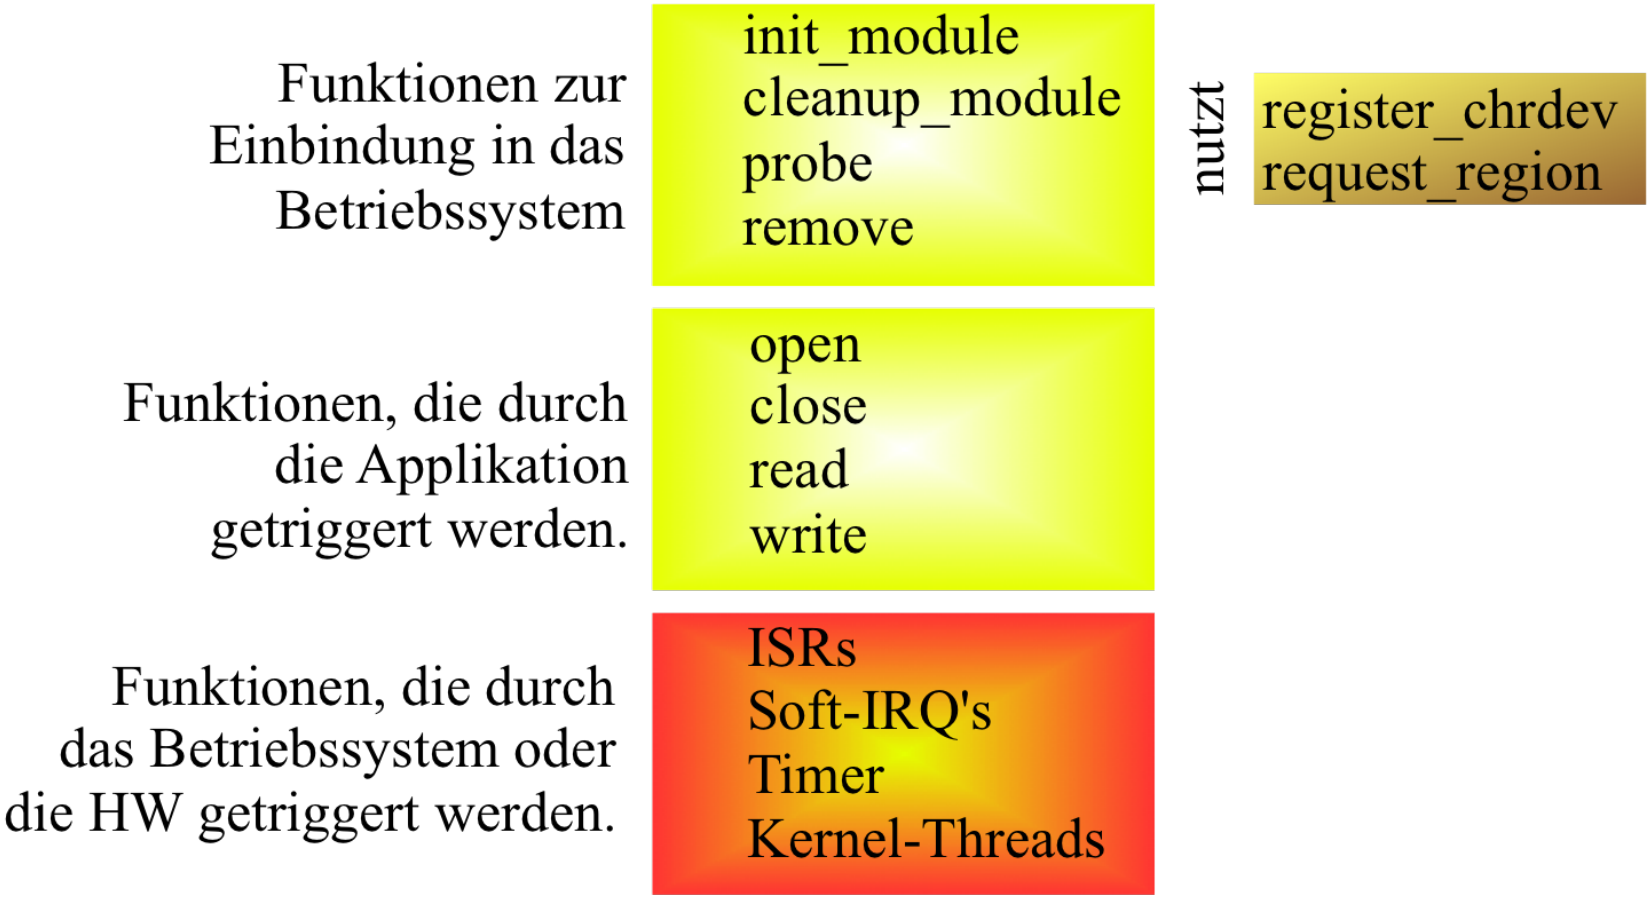

Zusammenfassung

- Linux besitzt einen monolithischen Betriebssystemkern.
- Linux hat ein modernes Prozess-, Memory- und IO-Management.
- Linux entwickelt sich sehr schnell weiter.
- Besondere Entwicklungsschwerpunkte zur Zeit:
  - Virtualisierung
  - Echtzeitverhalten
  - Sicherheit